[실습] Pandas + Seaborn 분석 리포트

고객 리뷰 데이터 **EDA(**탐색적 데이터 분석**)** 보고서

AI 3기 **2**반 김남형

목 차

1단계 데이터 전처리

1.1 데이터 로드 및 구조 확인

1.2 결측치 확인 및 처리 전략

1.3 분포 시각화 및 이상치 탐지

2단계 기술 통계 및 시각화

2.1 수치형 변수 기술 통계 요약

2.2 카테고리별 평균 평점 (Barplot)

2.3 평점과 감성 점수의 관계

2.4 텍스트 길이와 평점의 관계 (Violin Plot)

3단계 AI 분석을 위한 인사이트 도출

Q1 Sentiment Score가 높을수록 평점이 높은가?

Q2 Review Length가 AI 임베딩 유사도에 영향을 주는가?

Q3 카테고리별 감성 점수 평균 차이가 존재하는가?

3.4 3줄 요약 Insight

1단계. 데이터 전처리

1.1 데이터 로드 및 구조 확인

분석에 사용한 데이터셋은 reviews_1000.csv로, 총 1,000건의 고객 리뷰로 구성되어 있습니다.

pandas read_csv()를 통해 DataFrame으로 불러왔으며, shape로 전체 크기를, dtypes로 컬럼별 자료형을 확인합니다.

컬럼명	데이터 타입	설명
review_id	str	리뷰 고유 식별자
product_id	str	상품 고유 식별자
category	str	상품 카테고리 (fashion / home / sports / electronics)
review_text	str	리뷰 원문 텍스트
review_length	int64	리뷰 텍스트의 문자 수
num_words	int64	리뷰 텍스트의 단어 수
sentiment_score	float64	감성 분석 점수 (-1: 부정 ~ +1: 긍정)
rating	int64	고객 평점 (1 ~ 5점)

▸ 데이터 로드 코드

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# macOS 한글 폰트 설정 (음수 기호 깨짐 방지 포함)
plt.rcParams['font.family'] = 'AppleGothic'
plt.rcParams['axes.unicode_minus'] = False

# CSV 파일 로드 → DataFrame
df = pd.read_csv('reviews_1000.csv')
print(df.shape)     # (1000, 8)
print(df.dtypes)    # 컬럼별 자료형 확인
print(df.head())    # 상위 5행으로 데이터 육안 확인
```

1.2 결측치 확인 및 처리 전략

isnull().sum()으로 컬럼별 결측치를 집계한 결과, 두 컬럼에서 결측치가 발견되었습니다.

컬럼명	결측치 수	결측 비율
review_text	5건	0.5%
sentiment_score	5건	0.5%

결측치 처리는 데이터 특성에 따라 두 가지 전략으로 나누어 적용하였습니다.

[수치형 컬럼 (sentiment_score) → 중앙값(Median)으로 대체]

평균(mean) 대신 중앙값(median)을 선택한 이유는 이상치(outlier)에 대한 강건성 때문입니다. sentiment_score처럼 -1~1 범위의 실수형 데이터는 극단값이 포함될 경우 평균이 왜곡될 수 있습니다. 중앙값은 정렬 후 가운데 값이므로 이상치에 영향을 받지 않아 분포를 더 안정적으로 대표합니다.

[범주형 컬럼 (review_text) → 최빈값(Mode)으로 대체]

문자열 데이터에는 "평균"이나 "중앙값" 개념이 없습니다. 예를 들어 "fashion", "home", "sports"의 평균은 의미가 없으므로, 가장 많이 등장한 값(최빈값)으로 대체하여 기존 분포를 최대한 유지합니다. mode()는 리스트를 반환하므로 [0]으로 첫 번째(최다 빈도) 값만 사용합니다.

[행 삭제 방식을 선택하지 않은 이유]

결측치가 있는 행을 삭제하면 분석 가능한 데이터 수가 줄어 통계적 신뢰도가 낮아집니다. 전체 1,000건 중 결측치는 0.5%(5건)로 매우 적으므로, 행 삭제보다 값 대체 방식이 데이터 손실을 최소화하면서 분석 품질을 유지하는 데 적합합니다.

[코드 구현 주의사항: pandas Copy-on-Write]

pandas 2.x 이상에서는 Copy-on-Write 정책으로 인해 df[col].fillna(..., inplace=True) 방식이 원본 DataFrame에 반영되지 않습니다. 반드시 df[col] = df[col].fillna(...) 형태로 재할당해야 실제로 적용됩니다.

▸ 결측치 처리 코드

```
missing = df.isnull().sum()
print(missing)  # 컬럼별 결측치 수 확인

if missing.sum() > 0:
    # 수치형 → 중앙값 대체 (pandas CoW 대응: 명시적 재할당)
    for col in df.select_dtypes(include='number').columns:
        if df[col].isnull().sum() > 0:
            df[col] = df[col].fillna(df[col].median())

    # 범주형(문자열) → 최빈값 대체
    for col in df.select_dtypes(include='str').columns:
        if df[col].isnull().sum() > 0:
            df[col] = df[col].fillna(df[col].mode()[0])
```

1.3 분포 시각화 및 이상치 탐지

수치형 변수 4개(review_length, num_words, sentiment_score, rating)에 대해 히스토그램(분포 형태)과 박스플롯(IQR 기반 이상치 탐지)을 2행 4열로 시각화하였습니다. IQR 이상치 기준: Q1 - 1.5×IQR 미만 또는 Q3 + 1.5×IQR 초과. 분석 결과 4개 변수 모두 이상치 0건으로 확인되었습니다.

▸ 분포 시각화 코드

```
numeric_cols = ['review_length', 'num_words', 'sentiment_score', 'rating']
fig, axes = plt.subplots(2, 4, figsize=(18, 8))

for i, col in enumerate(numeric_cols):
    # 히스토그램: 분포 형태 시각화 + 평균 기준선
    axes[0, i].hist(df[col], bins=20, color='steelblue', edgecolor='white',
alpha=0.8)
    mean_val = df[col].mean()
    axes[0, i].axvline(mean_val, color='red', linestyle='--', label=f'평균:
{mean_val:.2f}')

    # 박스플롯: IQR 기준 이상치 탐지
    axes[1, i].boxplot(df[col], patch_artist=True,
                       boxprops=dict(facecolor='lightcoral', color='darkred'),
                       medianprops=dict(color='navy', linewidth=2))

    # IQR 이상치 계산
    Q1, Q3 = df[col].quantile(0.25), df[col].quantile(0.75)
    IQR = Q3 - Q1
    outliers = df[(df[col] < Q1 - 1.5*IQR) | (df[col] > Q3 + 1.5*IQR)]
    axes[1, i].set_xlabel(f'이상치: {len(outliers)}개')

plt.savefig('step1_distribution_outlier.png', dpi=150, bbox_inches='tight')
```

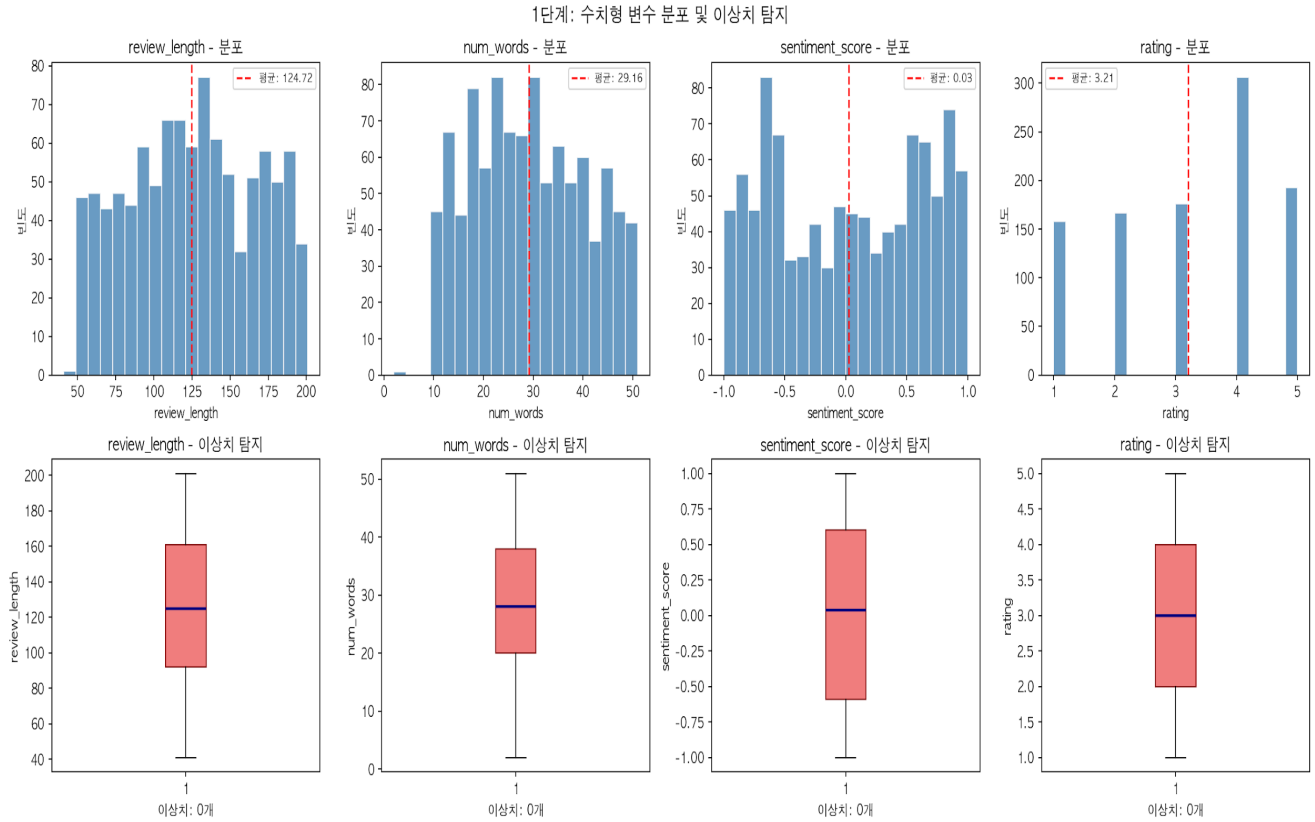

[그림 1] 수치형 변수 분포(상) 및 IQR 기반 이상치 탐지 박스플롯(하)

2단계. 기술 통계 및 시각화

2.1 수치형 변수 기술 통계 요약

describe()로 count / mean / std / min / 사분위수 / max를 산출하였습니다.

통계량	review_length	num_words	sentiment_score	rating
count	1,000	1,000	1,000	1,000
mean	124.72	29.17	0.025	3.21
std	41.61	11.31	0.616	1.36
min	41	2	-1.000	1
25%	92	20	-0.590	2
50%	125	28	0.040	3
75%	161	38	0.600	4
max	201	51	1.000	5

▸ 기술 통계 코드

```
numeric_cols = ['review_length', 'num_words', 'sentiment_score', 'rating']
desc = df[numeric_cols].describe().round(3)
print(desc)
```

2.2 카테고리별 평균 평점 / 2.3 평점-감성 점수 관계 / 2.4 텍스트 길이-평점 관계

- (좌) 카테고리별 평균 평점 Barplot: home(3.28) > fashion(3.25) > electronics(3.17) > sports(3.12). 카테고리 간 차이는 크지 않으며 전체 평균(3.21) 기준선으로 비교.
- (중) 평점 vs 감성 점수 Scatter + 회귀선: 피어슨 상관계수 0.735. 95% 신뢰구간 음영 표시. seaborn regplot 사용(np.polyfit SVD 수렴 오류 방지).
- (우) 텍스트 길이 vs 평점 Violin Plot: 평점별 review_length 분포 형태가 유사 → 평점이 텍스트 길이에 큰 영향을 주지 않음.

▸ 2단계 시각화 코드

```
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

# (좌) category별 평균 평점 barplot
cat_rating = df.groupby('category')['rating'].mean()
               .sort_values(ascending=False).reset_index()
colors = sns.color_palette('Blues_d', len(cat_rating))
bars = axes[0].bar(cat_rating['category'], cat_rating['rating'],
```

```
                    color=colors, edgecolor='gray')
axes[0].axhline(df['rating'].mean(), color='red', linestyle='--')  # 전체 평균선

# (중) 평점 vs 감성 점수: regplot (scatter + 회귀선 + 95% 신뢰구간)
# np.polyfit() SVD 실패 문제를 피하기 위해 sns.regplot 사용
sns.regplot(data=df, x='sentiment_score', y='rating',
            scatter_kws={'alpha': 0.4, 's': 20, 'color': 'steelblue'},
            line_kws={'color': 'red', 'linewidth': 2}, ci=95, ax=axes[1])
corr = df['sentiment_score'].corr(df['rating'])  # 피어슨 상관계수

# (우) 텍스트 길이 vs 평점: violin plot
# hue='rating' + legend=False: seaborn 최신 버전 palette 경고 해결
rating_order = sorted(df['rating'].unique())
sns.violinplot(data=df, x='rating', y='review_length', order=rating_order,
               hue='rating', palette='muted', inner='quartile',
               legend=False, ax=axes[2])

plt.savefig('step2_statistics_visualization.png', dpi=150, bbox_inches='tight')
```

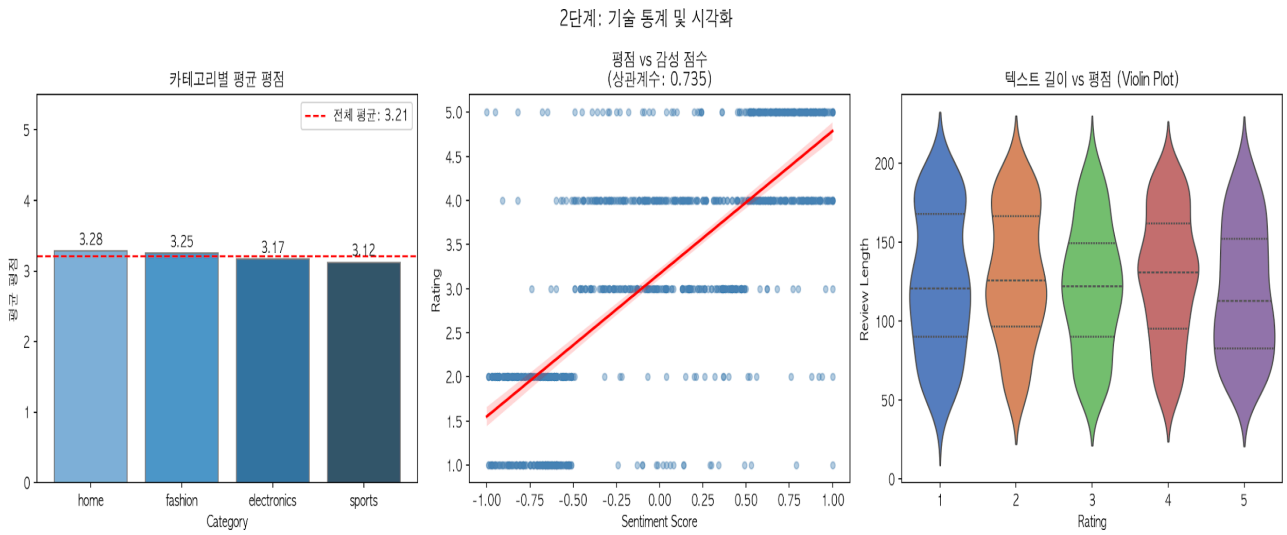

[그림 2] 카테고리별 평균 평점(좌) / 평점-감성 점수 회귀(중) / 텍스트 길이-평점(우)

3단계. AI 분석을 위한 인사이트 도출

고객 리뷰 데이터를 LLM 임베딩 기반 추천 시스템에 활용하기 전, 세 가지 핵심 질문에 대한 그래프 기반 분석을 수행하였습니다.

Q1. Sentiment Score가 높을수록 평점(Rating)이 높은가?

평점(1~5)별 평균 감성 점수를 집계한 결과, 평점 1·2는 각각 -0.607, -0.605(음수/부정), 평점 4·5는 +0.309, +0.594(양수/긍정)로 계단형 상승 패턴이 확인됩니다. 피어슨 상관계수 0.735로 중간 이상의 양의 선형 관계가 존재합니다.

> 다만 상관계수가 1에 가깝지 않고 분산이 크므로, 감성 점수를 평점 예측의 단독 지표로 사용하기보다 보조 특성(feature)으로 활용하거나 별도 보정이 필요합니다.

Q2. Review Length가 AI 임베딩 유사도에 영향을 줄 수 있는가?

텍스트 길이를 짧음(~120자) / 보통(121~150자) / 긺(151~)으로 구분한 결과, 짧은 리뷰가 전체의 약 절반(~450건)으로 가장 많았습니다. 구간별 평균 감성 점수 차이는 -0.02~+0.04 수준으로 매우 작아, 텍스트 길이가 감성 점수에 직접적인 영향을 미치지 않는 것으로 보입니다.

> LLM 임베딩 관점에서 짧은 텍스트(~120자)는 정보량 부족으로 임베딩 벡터의 표현력이 저하될 수 있어 유사도 신뢰성이 낮아질 가능성이 있습니다. 최소 길이 필터링 또는 텍스트 보강 전처리를 권장합니다.

Q3. 카테고리별 감성 점수 평균 차이가 존재하는가?

카테고리별 집계 결과: sports(0.048) > fashion(0.027) > electronics(0.026) > home(-0.002). 차이가 0.05 미만으로 매우 작고, 각 카테고리의 표준편차는 약 0.6(평균의 20배 이상)입니다. 이를 boxplot으로 시각화하여 전체 분포와 평균(◆)을 함께 표현하였습니다.

카테고리 간 차이가 통계적으로 유의미한지는 ANOVA 또는 Kruskal-Wallis 검정이 추가로 필요합니다. AI 추천 시스템 설계 시 카테고리별 감성 기준선(baseline)을 다르게 설정하는 전략을 고려할 수 있습니다.

▸ 3단계 인사이트 코드

```
fig, axes = plt.subplots(1, 3, figsize=(18, 5))

# Q1: 평점별 평균 감성 점수 barplot (RdYlGn 색상 그라데이션)
rating_sentiment = df.groupby('rating')['sentiment_score'].mean().reset_index()
colors_q1 = sns.color_palette('RdYlGn', len(rating_sentiment))
axes[0].bar(rating_sentiment['rating'].astype(str),
            rating_sentiment['sentiment_score'], color=colors_q1)
axes[0].axhline(0, color='black', linewidth=0.8)  # 중립선(0) 표시

# Q2: 텍스트 길이 구간화 후 이중 y축 barplot
df['length_bin'] = pd.cut(df['review_length'],
                          bins=[0, 120, 150, 200],
                          labels=['짧음(~120)', '보통(121~150)', '긺(151~)'])
ax2_twin = axes[1].twinx()  # 오른쪽 y축 추가

# Q3: 카테고리별 감성 점수 boxplot + 평균 마커 overlay
# barplot+오차막대 대신 boxplot 사용: 표준편차(~0.6)가 평균(~0.03)보다 커서
# 오차막대가 막대를 가리는 가독성 문제 해결
sns.boxplot(data=df, x='category', y='sentiment_score',
            hue='category', palette='Set2', width=0.5,
            legend=False, ax=axes[2])
axes[2].scatter(range(len(categories)), means,
                marker='D', color='red', s=60, zorder=5, label='평균')

plt.savefig('step3_ai_insight.png', dpi=150, bbox_inches='tight')
```

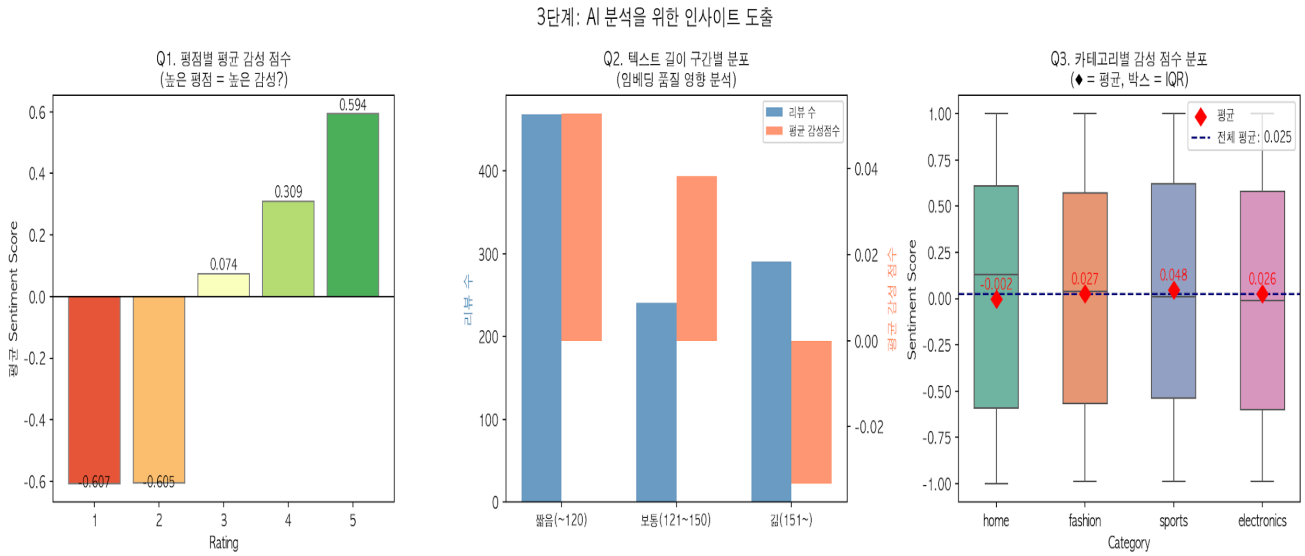

[그림 3] Q1 평점별 감성 점수(좌) / Q2 텍스트 길이 구간 분포(중) / Q3 카테고리별 감성 점수 분포(우)

3.4 3줄 요약 Insight

Q1	평점과 감성 점수는 상관계수 0.735로 양의 관계이나, 분산이 커서 감성 점수만으로 평점을 예측하기 어렵다. → AI 모델 설계 시 감성 점수를 단독 지표가 아닌 보조 특성으로 활용하고 별도 보정이 필요하다.
Q2	review_length 구간별 감성 점수 차이는 미미하나, 짧은 리뷰(~120자)는 LLM 임베딩 시 정보량 부족으로 유사도 신뢰성이 낮아질 수 있다. → 최소 길이 필터링 또는 텍스트 보강(augmentation) 전처리를 권장한다.
Q3	카테고리별 감성 점수 평균 차이는 0.05 미만으로 매우 작고, 표준편차(~0.6)가 커서 분포 폭이 넓다. → 통계적 유의성 검정(ANOVA 등)이 추가로 필요하며, 카테고리별 감성 기준선을 별도 설정하는 전략을 고려해야 한다.